



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目：基于多记忆增强模块及图像轮廓重建的工业表面异常检测
作者：杨曜，许湘云，张琳娜，陈建强，岑翼刚，黄彦森
网络首发日期：2024-10-28
引用格式：杨曜，许湘云，张琳娜，陈建强，岑翼刚，黄彦森. 基于多记忆增强模块及图像轮廓重建的工业表面异常检测[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20241025.1428.002>



网络首发：在编辑部工作流程中，稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定，且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式（包括网络呈现版式）排版后的稿件，可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定；学术研究成果具有创新性、科学性和先进性，符合编辑部对刊文的录用要求，不存在学术不端行为及其他侵权行为；稿件内容应基本符合国家有关书刊编辑、出版的技术标准，正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性，录用定稿一经发布，不得修改论文题目、作者、机构名称和学术内容，只可基于编辑规范进行少量文字的修改。

出版确认：纸质期刊编辑部通过与《中国学术期刊（光盘版）》电子杂志社有限公司签约，在《中国学术期刊（网络版）》出版传播平台上创办与纸质期刊内容一致的网络版，以单篇或整期出版形式，在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊（网络版）》是国家新闻出版广电总局批准的网络连续型出版物（ISSN 2096-4188，CN 11-6037/Z），所以签约期刊的网络版上网络首发论文视为正式出版。

基于多记忆增强模块及图像轮廓重建的工业表面异常检测

杨曜¹, 许湘云¹, 张琳娜¹, 陈建强¹, 岑翼刚², 黄彦森³

1. 贵州大学 机械工程学院, 贵阳 550025

2. 北京交通大学 计算机科学与技术学院, 北京 100044

3. 贵州大学 土木工程学院, 贵阳 550025

摘要：基于重建的工业图像异常检测通常假设模型能很好重建正常区域，而不能很好重建异常区域。但由于深度神经网络存在过度泛化问题，使得异常区域也能被较好重建，导致异常区域漏检。为解决上述问题，本文提出一种基于多记忆增强模块及图像轮廓重建的工业表面异常检测网络(Industrial Surface Anomaly Detection Based on Reconstruction with Multiple Memory Enhancement Modules and Image Edge, MMAERec)。具体来说，在带有跳跃连接的 U-Net 类型去噪自编码器上引入多记忆增强模块和图像轮廓提取模块。多记忆增强模块得到的记忆特征有利于很好地重建正常区域；而提取到的图像轮廓特征则有利于很好重建图像轮廓。将这两种不同特征的融合经注意力机制处理并用于重建能很好地提高重建图像质量。所提方法可以强制网络学习正常的低频和高频信息，防止模型直接复制异常区域，有效缓解过度泛化问题。在 MVTec AD 和 BTAD 两个工业数据集上的实验结果也展现了所提方法良好的检测和定位性能。

关键词：重建网络；多记忆增强模块；注意力机制；图像轮廓

文献标志码：A 中图分类号：TP391 doi: 10.3778/j.issn.1002-8331.2406-0293

Industrial Surface Anomaly Detection Based on Reconstruction with Multiple Memory Enhancement Modules and Image Edge

YANG Yao¹, XU Xiangyun¹, ZHANG Linna¹, CHEN Jianqiang¹, CEN Yigang², HANG Yansen³

1. School of Mechanical Engineering, Guizhou University, Guiyang 550025, China

2. School of Computer Science and Technology, Beijing Jiaotong University, Beijing 100044, China

3. School of Civil Engineering, Guizhou University, Guiyang 550025, China

Abstract：Reconstruction-based anomaly detection in industrial images usually assumes that the model can reconstruct the normal region well, but not the abnormal region well. However, due to the over-generalization problem of deep neural networks, abnormal regions can also be reconstructed well, resulting in the leakage of abnormal regions. In order to solve the above problems, this paper proposes an industrial surface anomaly detection based on reconstruction with multiple memory enhancement modules and image edge (MMAERec). Specifically, multiple memory enhancement modules and image edge extraction module are introduced on a UNet-type denoising self-encoder with skip connections. The memory features obtained from the multi-memory enhancement module facilitate a good reconstruction of the normal region; while the extracted image edge features facilitate a good reconstruction

基金项目：国家自然科学基金(62062021)；贵阳市科技计划项目(筑科合同[2023] 48-11)。

作者简介：杨曜(1998-)，男，硕士研究生，CCF 会员，研究方向为图像与视频异常检测；许湘云(2000-)，女，硕士研究生，研究方向为图像处理；张琳娜(1977-)，通信作者，女，硕士，副教授，研究方向为图像与视觉信息计算，E-mail: zln770808@163.com；陈建强(1975-)，男，硕士，副教授，研究方向为模式识别；岑翼刚(1978-)，男，博士，教授，研究方向为计算机视觉、信号处理；黄彦森(1986-)，男，博士研究生，研究方向为机器视觉。

of the image contour. The fusion of these two different features processed by the attention mechanism and used for reconstruction can improve the quality of the reconstructed image very well. The proposed method can force the network to learn normal low-frequency and high-frequency information, preventing the model from directly replicating the abnormal regions, and effectively alleviating the overgeneralization problem. Experimental results on two industrial datasets, MVTec AD and BTAD, also demonstrate the good detection and localization performance of the proposed method.

Key words: Reconstruction network; Multiple memory enhancement modules; Attentional mechanism; Image edge

工业表面异常检测旨在识别制造过程中产品出现的可见缺陷,它在制造质量控制中起着重要的作用。虽然现有的监督模型在许多图像异常任务中取得了良好的性能,但在实际应用中,由于生产工艺的提升,很难收集到足够多的缺陷样本来进行模型训练。该问题可以通过使用无监督异常检测模型^[1-3]得到很好的缓解。一方面,生产线上能收集到足够的正常样本,这足以训练一个没有缺陷样本的异常检测模型。另一方面,在正常样本上训练的模型能很好学习到正常样本数据的分布。因此,理想情况下,由正常样本训练得到的模型能够检测到任何偏离正常样本分布的未知缺陷。

现有的工业异常检测方法主要分为基于特征的方法^[4-7]和基于重建的方法^[8-10]。基于特征的方法大多采用预训练网络(如在大型数据集 ImageNet^[11]上训练得到)将原始图像提取到的特征投影到更可区分的特征空间中。基于重建的方法假设在仅使用正常样本训练的模型能很好地重建正常区域,而不能重建异常区域,因此可通过比较原始图像和重建图像之间的差异来检测异常。与基于特征的方法相比,基于重建的方法可以直接观察到原始图像和重建图像之间的差异,更容易在视觉上理解。

目前,大多数基于重建的方法由于模型容易过度泛化而表现不佳。具体来说,泛化能力强的模型能较好的将异常区域重建,而泛化能力较差则不能很好重建部分正常区域^[12],这使得异常的检测容易出现误检和漏检。此外,在重建过程中,图像的边缘轮廓会产生模糊,容易影响模型对异常的判断和定位,这给异常评估函数带来了挑战。

针对上述问题,本文提出了一种基于多记忆增强模块及图像轮廓重建的工业表面异常检测网络(MMAERec),从两个方面提高基于重建方法的性能。一方面,引入多记忆增强模块,该模块在训练过程中

只学习正常样本数据分布,对提取到输入图像的多尺度特征进行处理,得到的记忆特征更符合正常样本特征。利用得到的记忆特征进行重建能让模型对正常区域进行很好重建,而不能很好地重建异常,这有效缓解了过度泛化问题。另一方面,我们在记忆特征的基础上进一步结合了图像轮廓特征,因为提取到的图像轮廓特征保留了重要的原始高频分量,在训练阶段中,以图像灰度轮廓作为输入能让模型学习正常轮廓的分布,在测试过程中能让模型利用提取到的图像轮廓信息用于重建,缓解重建图像正常区域轮廓模糊的问题,有效提高模型对异常的检测性能。考虑到编码器在对输入图像进行编码的过程中存在下采样过程,而下采样过程会丢失部分特征信息,如果仅使用提取到的最后一层特征用于重建,重建图像虽然能保留语义信息,但会丢失较多的细节信息,为此,我们在对应的编码层和解码层之间添加跳跃连接,将编码器提取到的多尺度图像轮廓特征和记忆增强模块处理得到的多尺度记忆增强特征的融合经注意力模块处理后输入到解码器进行重建。融合的浅层特征保留了细粒度信息,而深层特征保留了语义信息。因此,在对应的编码层和解码层之间添加跳跃连接不仅充分弥补因下采样丢失的特征信息,还能充分利用浅层和深层特征用于重建,有效提升了图像重建质量。总的来说,利用处理得到记忆特征和提取到的图像轮廓特征的融合进行重建,使得重建图像信息更真实和全面,提升了模型重建质量及异常检测能力。

本文的贡献总结如下:

(1) 提出了一种新的重建方法,即将由多个记忆增强模块处理得到的符合正常样本分布的记忆特征与提取到的输入图像轮廓特征进行融合用于重建。利用处理得到的记忆特征进行重建能提升模型对正常区域的重建能力并抑制对异常区域的重建,有效缓解过度泛化问题。而提取到的轮廓特征很好地保

留图像中的边缘轮廓信息,有效缓解重建图像轮廓模糊的问题,显著提高了模型异常检测性能。

(2) 针对网络下采样过程中图像信息的丢失,本文将融合的两种特征使用注意力模块进行筛选及整合,并进一步使用跳跃连接将其输入到解码器以弥补丢失的信息,跳跃连接和注意力模块的使用使得模型的鲁棒性得到有效提高。

(3) MMAERec 在具有挑战性的基准 MVTEC AD^[13]和 BTAD^[14]数据集上进行广泛的实验研究,验证了本文方法在异常分类和定位任务中的优越性。

1 相关工作

现有的研究方法主要分为两类:基于特征的方法和基于重建的方法。

1.1 基于特征的方法

基于特征的方法^[4, 7, 15-17]通常将提取到的正常样本的特征表示为可测量的分布,以找到一个可完全区分正常和异常特征的特征空间。该方法通常利用在大型数据集上预训练的网络作为特征提取器。例如,SPADE^[7]采用预训练网络提取所有正常图像特征来构造一个特征记忆库;PaDiM^[4]利用预训练网络对输入图像进行分块补丁嵌入。该方法通过计算正常样本和测试样本分布之间的统计距离并将其作为异常分数来实现检测任务。然而,由于计算量大、可解释性差以及无法引入相关的先验知识,使得基于特征的方法很难针对模型的具体情况进行优化。

1.2 基于重建的方法

基于重建的方法通常被描述成使用生成模型对图像进行重建的任务。常用生成模型如自动编码器^[18-20]、VAEs^[21]、GANs^[22-23]等。多数已有的研究主要利用去噪自编码器^[20, 24-25]来帮助网络更好地捕获正常数据分布,从而避免对异常的直接输出。在训练阶段,这些方法在原始图像中加入一定的噪声(如高斯噪声、几何变换^[26-27]等),并要求模型消除图像上的噪声。尽管这些方法在性能上有所提高,但由于样本上的伪异常仍然与真实存在较大的差异,使得模型并没有对异常有准确的认知,导致过度泛化问题没能被很好解决。在此基础上,EdgRec^[12]提出一个特定的属性移除-恢复任务,其使用提取到的图像灰度轮廓进行重建,其中低频和颜色属性是

要恢复的主要属性,但仅使用灰度轮廓图进行重建使得重建图像信息并不真实和完整。此外,早期重建方法的评价函数主要包括 l_2 距离、结构相似度(SSIM)^[28]等。Zavrtanik 等^[18]引入多尺度梯度量级相似性(MSGMS)作为异常评价函数,显著地提高了模型的异常定位性能,但 MSGMS 对低频颜色的检测效果并不佳。基于此,本文提出一种基于多记忆增强模块及图像轮廓重建的工业表面异常检测网络(MMAERec),从缓解过度泛化问题及提高重建图像质量两方面分别引入多记忆增强模块和图像轮廓用于重建。记忆特征和图像轮廓特征的融合能让模型在仅使用不包含异常信息的记忆特征进行重建的基础上进一步提高图像轮廓重建质量,有效提高模型的检测性能。同时,提出一种关于颜色的评价函数,并将其与 MSGMS 相结合作为最终的评价函数,实现对各种异常的有效检测。

2 研究方法

本文方法的训练和测试阶段流程如图 1 所示。具体来说,先将原始图像 I 转换为灰度图 I_g ,再对 I_g 使用膨胀和腐蚀操作并作差分运算,得到图像轮廓图 I_e 。同时,分别将 I 和 I_e 输入到特征提取器和编码器,将多记忆增强模块处理得到的记忆特征与提取到的图像轮廓特征进行融合,并利用注意力模块对融合的特征信息进行整合和筛选,最后用跳跃连接将处理好的特征信息输入到解码器进行重建。在训练阶段使用损失函数计算原始图像 I 和重建图像 I_r 之间的误差并进行反向传播;而测试阶段则使用评价函数对比原始图像 I 和重建图像 I_r 得到异常定位图 A 。在图 1 中,上半部分为多记忆增强模块,其通过正常样本进行训练生成,可较好地学习到正常样本的特征分布,提升网络对正常样本或异常样本中正常区域的重建能力,生成更加符合正常样本分布的特征。同时,可减弱由于网络泛化性导致的对异常区域的重建能力。在测试阶段,由于所提取的正常区域的多尺度特征在下采样过程中存在信息丢失,所以记忆增强模块通过计算输入的正常区域特征与记忆项的相似度,并经过阈值筛选保留与输入特征相似度大的记忆项,将保留的记忆项通过线性组合实现对正常区域特征的有效逼近,所得到的记忆特征弥补了下采样过程中的信息丢失,且符

合正常样本分布,有效提升对正常区域的重建效果。另外,重建图像的轮廓模糊容易导致异常区域的误检及漏检,因此图1中下半部分为图像轮廓特征提取模块,通过网络训练阶段学习正常图像轮廓特征,并与多记忆增强模块输出相融合,提升重建图像尤其是图像正常区域轮廓重建质量,降低由于轮廓重建不佳带来的性能下降。

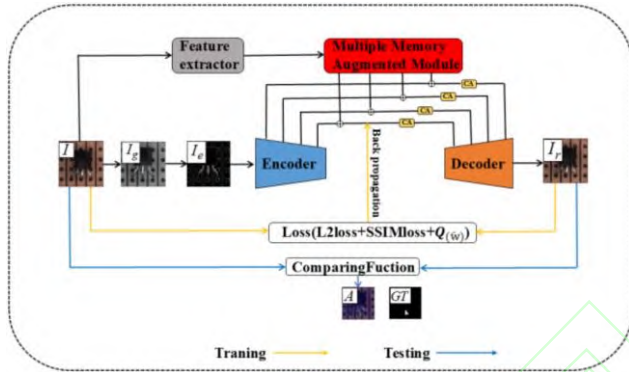


图1 MMAERec 的训练及测试阶段流程图(注:GT为真实缺陷标注)

Fig.1 Flowchart of the training and testing phase of MMAERec (Note: GT is labeled with real defects)

2.1 提取图像的轮廓

本文在训练和测试阶段都对输入图像进行轮廓提取。如图2所示为提取图像轮廓的流程,首先将原始图像 I 转换为灰度图 I_g , 然后,使用 3×3 的卷积核分别对灰度图 I_g 进行膨胀和腐蚀操作,并进行差分运算得到图像轮廓图 I_e 。为了在测试阶段能更好地对图像轮廓进行重建,本文首先将得到的图像轮廓输入到训练好的编码器中,提取出符合正常样本的分布的轮廓特征。然后再将提取到的图像轮廓特征与记忆特征进行融合。记忆特征保留了丰富正常图像的信息,而轮廓特征能很好补充重建图像的轮廓信息。将这两种不同的特征信息融合,能更好地提升模型对图像轮廓的重建能力,进而提升图像重建质量。相较于仅使用 RGB 图像作为输入而言,本方法由于单独提取正常图像轮廓融于图像重建,当输入图像中有异常区域时,所提方法能提升对正常

区域轮廓的重建能力,但减弱对异常区域的重建能力,最终提升模型对异常区域的检测性能。




图2 提取图像轮廓流程图

Fig.2 Flowchart for extracting image edge

2.2 多记忆增强模块

由于卷积神经网络具有较强的特征提取能力,容易产生过度泛化问题,导致仅使用正常样本训练良好的重建模型也能很好的对异常进行重建。而本文针对该问题设计了多记忆增强模块。对特征提取器提取到的多尺度特征的每一层都使用记忆增强模块进行增强处理。具体的一个记忆增强模块(Memory Augmented Module, MeAM)如图3所示,记忆库 $M = \{m_1, m_2, m_3, \dots, m_N\} \in \mathbb{R}^{N \times C}$ 定义为包含 N 个固定维数为 C 的记忆项实值矩阵,为了利于记忆项的更新,本文将记忆项实值矩阵转换为可训练的参数。我们假设 C 与输入查询向量 z 的维数相同, $Z = \mathbb{R}^C$ 。 m_i 表示记忆库中的行向量, $1 \leq i \leq N$ 。与[18, 19]类似,存储器是内容可寻址的,它是通过计算查询向量 z 与内存库中每个行向量 m_i 之间的相似性关注权重 w 来解决的。具体来说,每个权重 w_i 的计算公式如下:

$$w_i = \frac{\exp\left(\frac{zm_i^T}{\|z\| \|m_i\|}\right)}{\sum_{j=1}^N \exp\left(\frac{zm_j^T}{\|z\| \|m_j\|}\right)} \quad (1)$$

式中, w_i 是非负的, $w \in \mathbb{R}^{1 \times N}$ 中的所有元素的和等于 1。然而,仅使用权重 w 将记忆项进行线性组合,使得一些与正常特征向量相似度不大的记忆项也能被用于组合,导致部分异常仍可能被很好地重建。为了缓解这个问题,可以采用阈值筛选来提高 w 的稀疏性,但由于该策略并不能进行反向传播,因此结合

使用 ReLU 激活函数来实现权重筛选, 计算公式如下:

$$\hat{w}_i = \frac{\max(w_i - \lambda, 0) \cdot w_i}{|w_i - \lambda| + \varepsilon} \quad (2)$$

其中 $\max(.,0)$ 表示 ReLU 激活函数, \hat{w}_i 表示筛选后存储器寻址权重向量 \hat{w} 的第 i 项, ε 是一个很小的正标量。在实践应用中, 设置阈值 $\lambda \in [\frac{1}{N}, \frac{3}{N}]$ 。最后再将 \hat{w}_i 重新归一化, 得 $\hat{w}_i = \hat{w}_i / \|\hat{w}\|_1$ 。为了进一步提高权重 \hat{w} 的稀疏性, 我们在训练过程中将权重 \hat{w} 的熵最小化, 通过反向传播使记忆项学习正常样本的分布, 以实现记忆项的更新; 在测试阶段, 将

训练得到的记忆项进行固定, 并从中获取用于重建的记忆特征。因此, 给定输入查询向量 z , 使用记忆项的线性组合得到符合正常样本特征分布的输出逼近向量 \hat{z} , 计算公式如下所示:

$$\hat{z} = \hat{w}M = \sum_{i=1}^N \hat{w}_i m_i \quad (3)$$

输出向量 \hat{z} 有效保留了正常样本信息。因此, 对于正常区域, 模型自然可以很好地重建。相反, 异常区域的特征输入则会被记忆项的线性组合, 将异常区域尽可能的逼近为正常, 从而导致在异常区域上与输入图像产生较大的重构错误, 有效提高模型异常检测准确性, 缓解了过度泛化问题。

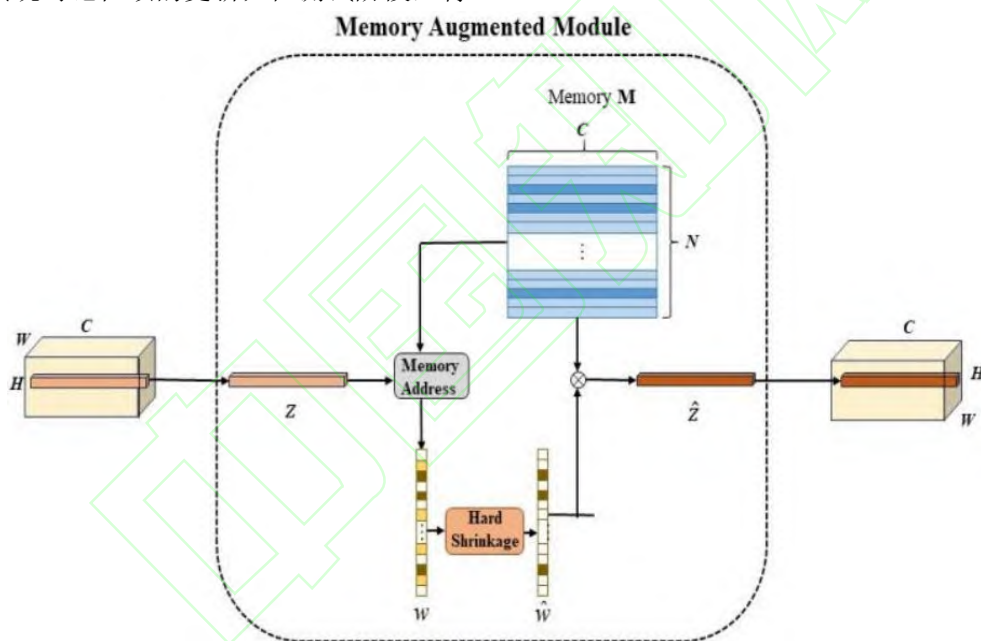


图3 记忆增强模块工作流程图

Fig.3 Memory Enhancement Module Workflow Diagram

2.3 重建网络

本文的重建网络架构具体如图4所示。MMAERec首先在相应的编码器和解码器之间添加了跳跃连接, 并在此基础上引入多记忆增强模块来获得正常记忆特征, 并将正常记忆特征与编码器提取得到的轮廓特征进行相加融合。考虑到对于许多重建网络^[29-30]在添加跳跃连接后会将异常区域直接进行复制并用于重建, 从而导致异常检测效果并不佳。但在本文中, 在特征进入解码器之前, 我们首先利用多记忆增强模块来提升解码器对样本中正常区域的逼近能力, 减弱对异常区域的逼近能力。即对于一个输入的测试图像, 在利用多记忆增强模块对图

像特征进行逼近的过程中, 其不但能很好的逼近图像正常区域, 而且还能尽可能的将异常区域也逼近为正常区域, 因此避免了跳跃连接在重建时直接复制异常区域导致的检测性能下降问题。除了上述利用多记忆增强模块提升正常图像区域的重建能力之外, 进一步, 本文还将正常图像轮廓输入编码器进行学习, 使得编码器输出能很好的学习到正常样本轮廓特征分布, 通过将提取出得到轮廓特征与记忆特征进行融合用于重建, 能让模型很好地重建出正常区域及轮廓, 而不能对异常轮廓区域进行很好重建。最后使用注意力模块对融合后的记忆特征和图像轮廓特征进行筛选并输入到解码器用于重建。本文的

相关实验验证了通过将提取到的轮廓特征与记忆特征进行融合用于重建,能很好处理异常区域,也很

好地重建出正常区域。充分证明了所提方法对模型重建质量的有效性。

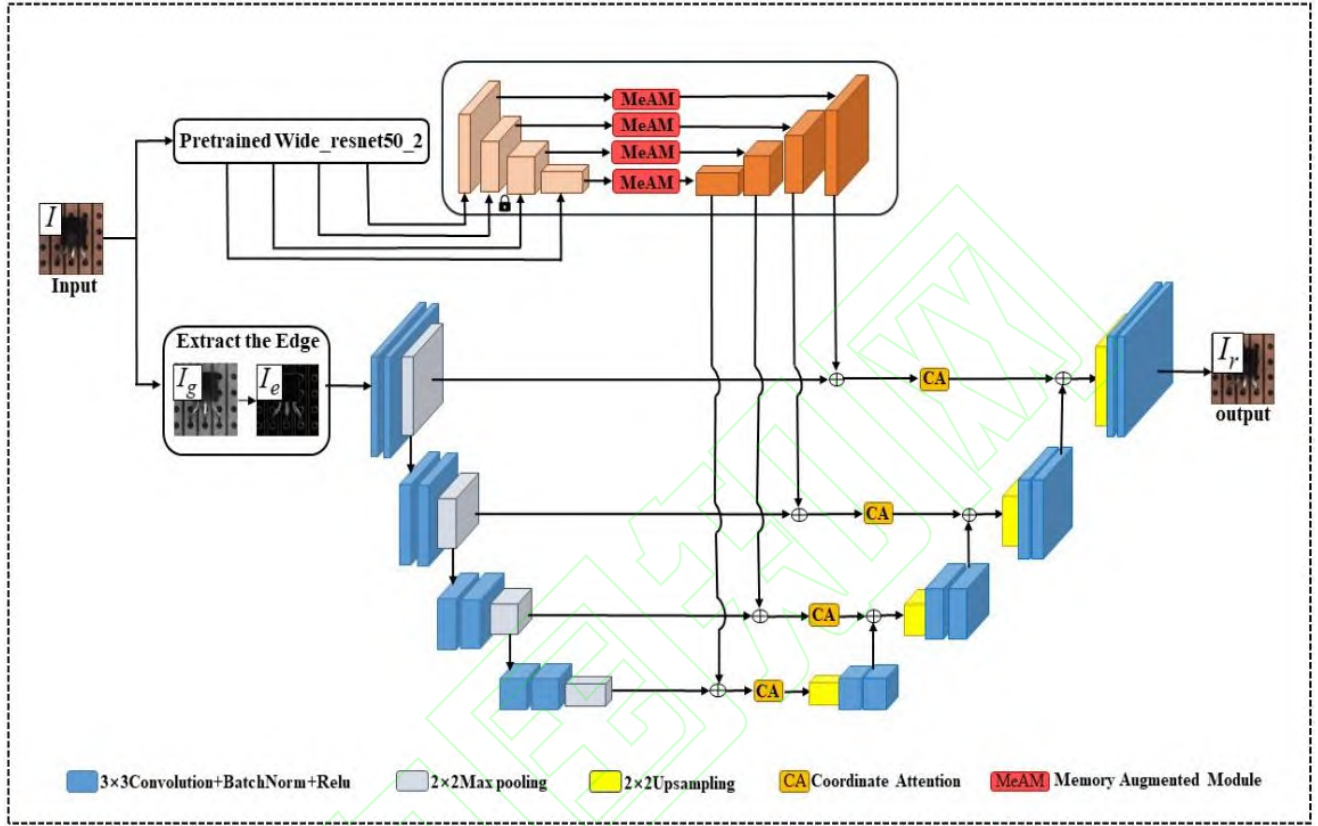


图4 MMAERec 的重建网络架构

Fig.4 Reconstructed network architecture of MMAERec

具体来说,对于一张输入图像 I ,首先将 I 转换为灰度图 I_g ,然后对其进行轮廓提取得到 I_e ,再将 I_e 输入到编码器提取出前四层特征,得到图像轮廓特征维度分别为 $1 \times 128 \times 128 \times 128$ 、 $1 \times 256 \times 64 \times 64$ 、 $1 \times 512 \times 32 \times 32$ 和 $1 \times 1024 \times 16 \times 16$ 。同时,将输入图像 I 也输入到在 ImageNet 数据集上预训练的特征提取器 Wide_resnet50_2^[12]中,提取前四层特征,其特征维度分别为 $1 \times 128 \times 128 \times 128$ 、 $1 \times 256 \times 64 \times 64$ 、 $1 \times 512 \times 32 \times 32$ 和 $1 \times 1024 \times 16 \times 16$,再将这四层特征分别输入到多个记忆增强模块,使得到的记忆特征更符合正常样本分布。需要说明的是,为了保证输入图像的特征和正常记忆特征的统一,本文对 Wide_resnet50_2 中的 block0、block1、block2 和 block3 四个层的模型参数进行固定,但模型的其余部分仍然是可训练的。最后,将得到的轮廓特征和

对应的记忆特征相加,并经过坐标注意力模块整合并用于重建,得到重建图像 I_r 。

2.4 坐标注意力机制

注意力机制是用来提高模型对有用特征信息的关注度,最大程度对有用信息进行筛选和利用,在图像异常检测任务中应用广泛。SENet^[31]将注意力机制应用在特征图中重要通道上。注意分支网络^[32]利用多个特征图的聚合,得到一种用于分类的注意力图。本文使用坐标注意力机制 (Coordinate Attention^[33]) 将图像轮廓特征和增强的记忆特征在空间上进行相互关联。如图 5 所示,由于 MMAERec 的编码器在刚开始训练时没能学习到足够多的知识,所提取的轮廓特征深层信息可能只与增强后的记忆特征的部分浅层信息相似,采用坐标注意力机制能将这两种不同特征的不同层信息在空间上进行相互关联(如

将记忆特征第一层的绿色立方块信息与轮廓特征第二层的绿色立方块信息进行关联), 使得重建的特征

信息更加丰富, 利于提高重建图像质量及模型检测性能。

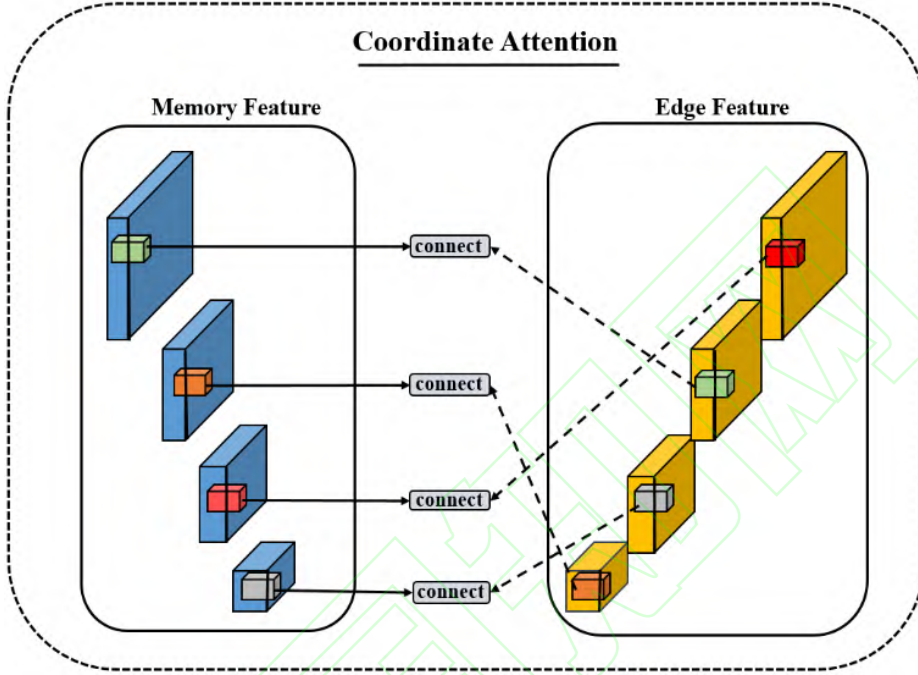


图5 坐标注意力机制作用原理

Fig.5 Principle of action of coordinate attention mechanism

2.5 损失函数

本文同时考虑了像素的 l_2 损失、基于图像块的 SSIM 损失^[14]以及关于提高 \hat{w} 的稀疏性的损失。其中, SSIM 损失使模型能够更好地学习到图像的结构信息, 从而减少重建图像的模糊区域。SSIM 损失函数为:

$$L_{SSIM}(I, I_r) = \frac{1}{N_p} \sum_{i=1}^H \sum_{j=1}^W 1 - SSIM(I, I_r)_{(i,j)} \quad (4)$$

式中, H 和 W 分别为原始图像 I 的高度和宽度, I_r 为重建图像。 N_p 为 I 中的像素个数。

$SSIM(I, I_r)_{(i,j)}$ 表示 I 和 I_r 中坐标为 (i,j) 的图像块之间的

SSIM 值。对于提高 \hat{w} 的稀疏性, 考虑到 \hat{w} 的所有项都是非负的, 且 $\|\hat{w}\|_1 = 1$, 在训练阶段, 本文将每个样本在提取的四个特征层上的内存寻址权值 \hat{w}^0 , \hat{w}^1 , \hat{w}^2 和 \hat{w}^3 的总熵 $Q_{(\hat{w})}$ 进行最小化, 计算公式定义如下:

$$Q_{(\hat{w})} = \sum_{i=1}^T \sum_{j=1}^4 [-\hat{w}_i^j \cdot \log(\hat{w}_i^j)] \quad (5)$$

T 表示输入样本的数量。最后, 结合 l_2 损失、式

(4)和式(5)得到最终损失函数为:

$$L(I, I_r) = l_2(I, I_r) + \theta L_{SSIM}(I, I_r) + \alpha Q_{(\hat{w})} \quad (6)$$

式中, θ 是用来调节个体损失对总体目标函数的优势度, 将 θ 设为 1, 能让模型很好地学习到图像的结构信息, 从而减少重建图像的模糊区域。

α 为训练中的超参数, 在最小化内存寻址权值的熵时, $\alpha = 0.0002$ 在我们的所有实验中的得到了理想的效果。我们在实验部分对参数 θ 和 α 的不同取值进行了相关的实验验证。

2.6 异常评价函数

本文从图像的结构和颜色差异两方面来设计评价函数。对于图像结构差异, MMAERec 使用多尺度梯度量级相似性 (Multi-scale Gradient Magnitude Similarity, MSGMS) 来检测。MSGMS 的作用原理是先计算原始图像与重建图像不同尺度特征的梯度量级相似性, 再取其平均值。结构差异评价函数如下:

$$G_{MSGM} = E_{H \times W} - f_{mean}(MSGMS(I, I_r)) \quad (7)$$

式中, H 和 W 表示原图 I 的高和宽, $E_{H \times W}$ 表示高为 H , 宽为 W 的单位矩阵。 $f_{mean}()$ 表示平滑异常图的卷积操作, 其卷积核大小设置为 21×21 。

对于颜色评价函数, 受到 EdgRec^[27] 的启发, 本文将原始图像和重建图像分别从 RGB 色彩空间转换到 CIELAB 色彩空间, 其色域较 RGB 更加宽阔, 也更符合人类视觉感知。与 EdgRec 只求其中两个通道颜色差异不同的是, MMAERec 在 CIELAB 色彩空间的三个颜色通道上分别去求差异, 因为光照也是实际应用场景中不可分割的影响因素。CIELAB 色彩空间的三个颜色通道分别为 L (表示从黑色到白色的亮度信息)、 a (表示从绿色到红色的颜色信息) 和 b (表示从蓝色到黄色的颜色信息)。将 RGB 图像转换为 CIELAB 图像的过程可以写成:

$$\begin{pmatrix} X \\ Y \\ Z \end{pmatrix} = \begin{pmatrix} 0.412453 & 0.357580 & 0.180423 \\ 0.212671 & 0.715160 & 0.072169 \\ 0.019334 & 0.119193 & 0.950227 \end{pmatrix} \begin{pmatrix} R \\ G \\ B \end{pmatrix} \quad (8)$$

$$L = 116f\left(\frac{Y}{Y_n}\right) - 16 \quad (9)$$

$$a = 500\left(f\left(\frac{X}{X_n}\right) - f\left(\frac{Y}{Y_n}\right)\right) \quad (10)$$

$$b = 200\left(f\left(\frac{Y}{Y_n}\right) - f\left(\frac{Z}{Z_n}\right)\right) \quad (11)$$

其中

$$f(w) = \begin{cases} w^{\frac{1}{3}}, & \text{if } w > \left(\frac{6}{29}\right)^3 \\ \left(\frac{841}{108}\right)w + \frac{4}{29}, & \text{else} \end{cases} \quad (12)$$

式中, X ; Y ; Z 表示在色彩空间转换过程中来自 CIEXYZ 空间的中间值。 X_n ; Y_n ; Z_n 为参考白点的 CIEXYZ 颜色值。本文的实验使用

OpenCV 库中的默认设置。因此, 最终图像颜色差异评价函数如下:

$$G_c = f_{mean}\left[\left((I^L - I_r^L)^2 + (I^a - I_r^a)^2 + (I^b - I_r^b)^2\right)\right] \quad (13)$$

其中 $f_{mean}()$ 的卷积核大小为 11×11 。 I^L , I^a , I^b 分别表示输入图像 I 转换到 CIELAB 色彩空间对应的 L , a , b 三个颜色通道。同理, I_r^L , I_r^a , I_r^b 分别表示重建图像 I_r 转换到 CIELAB 色彩空间中的三个颜色通道。

结合 G_{MSGM} 和 G_c 作为最终的异常评价函数 F_{all} 。为了让异常评分规范合理, 本文引入一个缩放因子 μ 使 G_{MSGM} 和 G_c 的数量级统一, 由于 G_c 和 G_{MSGM} 相差 3 个数量级。因此, 缩放因子 μ 设为 $1e^{-3}$, 使得模型的异常评估更加准确有效。最终的异常评价函数如下:

$$F_{all} = G_{MSGM} + \mu G_c \quad (14)$$

3 实验

我们在 MVTEC AD 和 BTAD 数据集上对 MMAERec 的性能进行评估。同时, 还与先进的表面异常检测方法进行比较, 并通过消融实验验证所提方法的有效性。

3.1 数据集

MVTEC AD 数据集是无监督工业视觉异常检测领域重要的基准数据集。该数据集包含 15 个类别, 其中纹理类别 5 个, 对象类别 10 个。其训练集 3629 张, 测试集 1725 张。且每个类别都包含用于训练的正常样本和用于测试的正常和异常混合的样本, 测试集包含各种不同纹理, 形状和规模的真实异常。

BTAD 数据集有 3 个类别共 2540 张图像, 其中训练集只包含正常图像, 测试集包含正常和异常混合的样本。

3.2 评价指标

本文使用异常检测中的标准度量 AUROC 对模型进行性能评估。图像级 AUROC 用于异常检测分类,像素级 AUROC 用于评估异常定位性能。由于许多异常只占图像小部分像素,像素级 AUROC 不能很好地反映实际的异常定位性能。因此,实验另外引入了像素平均精度度量(AP)和区域重叠曲线下的面积(AUPRO)来对异常定位的性能进行综合评价。

3.3 实现细节

所有实验都在 NVIDIA GeForce RTX 4070 上实现,将 MVTEC AD 和 BTAD 数据集的所有原始图像调整为 256×256 ,训练轮数设置为 600, batch size 设置为 4。MMAERec 使用 Adam 作为优化器,初始学习率为,当训练轮数为 300 和 480 时,

将学习率依次乘以 0.2。

3.4 与相关方法对比

在 MVTEC AD 数据集上。我们将所提出的 MMAERec 与基线方法^[14]、基于特征的方法^[4, 31, 34-36]和基于重建的方法^[10, 23, 37-38]在不同的指标进行了全面比较,表 1 展示了本文方法和其它方法的图像级检测性能,从表中可得,本方法在 4 个类别上达到最佳检测性能 100%,在 15 个类别上的平均 AUC 为 97%,超越了所有的竞争对手,相较于表现最高的竞争对手 Intra^[36],MMAERec 获得 1.1%的领先。Intra 采用属性移除-恢复任务,该方法只重建被遮挡的部分,但由于缺乏对图像的语义理解,使得重建部分存在模糊现象,而 MMAERec 将图像轮廓作为输入,有效减少重建图像的模糊区域,提升了模型的检测性能。

表 1 在 MVTEC AD 数据集上图像级检测结果对比(AUROC%)

Table 1 Comparison of image-level detection results on MVTEC AD dataset (AUROC%)

类别	AE-SSIM ^[19]	US ^[31]	DFR ^[34]	PaDim ^[4]	RIAD ^[14]	DAAD ^[35]	Intra ^[36]	Ours
地毯	87	91.6	97	99.8	84.2	86.6	98.8	96.3
铁丝网	94	81	98	96.7	99.6	95.7	100	100
皮革	78	88.2	99	100	100	86.2	100	100
瓷砖	59	99.1	86	98.1	93.4	88.2	98.2	99.6
木头	73	97.7	94	99.2	93	98.2	98	93.9
瓶子	93	99	97	99.9	99.9	97.6	100	99.7
电缆	82	86.2	92	92.7	81.9	84.4	84.2	96.9
胶囊	94	86.1	99	91.3	88.4	76.7	86.5	92.8
栗子	97	93.1	99	92	93.3	92.1	95.7	95.5
螺母	89	82	93	98.7	88.5	75.8	96.9	94.8
药片	91	87.9	97	93.3	83.8	90	90.2	98.5
螺丝	96	54.9	99	85.8	84.5	98.7	95.7	89.9
牙刷	82	95.3	99	96.1	100	99.2	99.7	100
晶体管	90	81.8	80	97.4	90.9	87.6	95.8	96.7
拉链	88	91.9	96	90.3	98.1	85.9	99.4	100
平均	92.1	87.7	95	95.5	91.7	89.5	95.9	97

(注:加粗的数字表示最好的性能,下划线表示第二好的性能)

(Note: Bolded numbers denote the best performance, and underlining denotes the second best performance)

表 2 和表 3 展示了本文方法和其它方法的像素级定位性能。从表 2 中可得, MMAERec 在 15 个类别上的平均 AUC 和平均 AP 分别为 97.4%和 55.7%,与基于重建的 RIAD^[3]相比, MMAERec 在平均 AUC

和平均 AP 上分别领先了 3.2%和 7.5%;而与基于特征方法中具有良好性能的 PaDim^[4]相比,其在平均 AUC 上持平,但在平均 AP 上领先后者 0.7。在表 3 中, MMAERec 在 15 个类别上的平均 PRO 为

91.1%，与性能表现最好的 NAS^[35]相比，所提方法获得 0.1%的领先。这主要归因于本方法所使用的颜色评估函数，该评分函数能实现准确的异常评估，有效提升模型的定位性能。表 2 和表

3 所展示的性能结果充分验证了本方法在像素级定位上的良好性能。同时，本方法在 MVTec AD 数据集 15 个类别上的异常定位效果如图 6 所示。

表 2 在 MVTec AD 数据集上像素级定位结果对比(AUROC%/AP%)

Table 2 Comparison of pixel-level localization results on the MVTec AD dataset (AUROC%/AP%)

类别	RIAD ^[14]	US ^[31]	PaDim ^[4]	Ours
地毯	96.3/ 61.4	93.5/52.2	99.0 / <u>60.7</u>	<u>98.3</u> /54.8
铁丝网	<u>98.8</u> / 36.4	89.9/10.1	97.1/ <u>35.7</u>	99.2 /32.8
皮革	<u>99.4</u> /49.1	97.8/40.9	99.0/ <u>53.5</u>	99.8 / 65.3
瓷砖	89.1/52.6	92.5/ <u>53.3</u>	<u>94.1</u> /52.4	98.6 / 76.9
木头	85.8/38.2	<u>92.1</u> / 53.3	94.1 / <u>46.3</u>	91.5/39.4
瓶子	<u>98.4</u> / <u>76.4</u>	97.8/74.2	98.2/ 77.3	98.5 /70.6
电缆	84.2/24.4	91.9/ 48.2	96.7 / <u>45.4</u>	<u>93.8</u> /42.1
胶囊	92.8/ <u>38.2</u>	<u>96.8</u> /25.9	98.6 / 46.7	<u>96.8</u> /35.2
栗子	96.1/33.8	<u>98.2</u> /57.8	98.1/ <u>61.1</u>	99.7 / 69.2
螺母	92.5/64.3	97.2/ <u>83.5</u>	<u>97.3</u> /77.4	97.8 / 83.7
药片	95.7/51.6	<u>96.5</u> / <u>62</u>	95.7/61.2	99.4 / 69.3
螺丝	98.8 / 43.9	97.4/7.8	<u>98.4</u> /21.7	96.3/ <u>40.9</u>
牙刷	98.9 / <u>50.6</u>	97.9/37.7	<u>98.8</u> / 54.7	98.9 /50.5
晶体管	87.7/ <u>39.2</u>	73.7/27.1	97.6 / 72.0	<u>92.3</u> /30.2
拉链	97.8/ <u>63.4</u>	95.6/36.1	<u>98.4</u> /58.2	99.6 / 75.1
平均	<u>94.2</u> /48.2	93.9/45.5	97.4 / <u>55</u>	97.4 / 55.7

(注：加粗的数字表示最好的性能，下划线表示第二好的性能)
(Note: Bolded numbers denote the best performance, and underlining denotes the second best performance)

表 3 在 MVTec AD 数据集上像素级定位结果对比(AUPRO%)

Table 3 Comparison of pixel-level localization results on the MVTec AD dataset (AUPRO%)

类别	AE-SSIM ^[19]	Ano-GAN ^[37]	NAS ^[35]	Ours
地毯	65	20	85	87.7
铁丝网	85	23	96.8	96.7
皮革	56	38	98.7	98.8
瓷砖	18	18	95.3	96.8
木头	61	39	85.3	79.7
瓶子	83	62	92.9	94.6
电缆	48	38	89.9	78.9
胶囊	86	31	91.4	90.5
栗子	92	70	93.6	92.8
螺母	60	32	94.6	89.5
药片	83	78	96	98.9
螺丝	89	47	90.1	87.6
牙刷	78	75	90.7	98.6
晶体管	73	55	75.3	75.8
拉链	67	47	89.2	98.9
平均	69	45	91	91.1

(注：加粗的数字表示最好的性能，下划线表示第二好的性能)

(Note: Bolded numbers denote the best performance, and underlining denotes the second best performance)




图6 MMAERec在MVTec AD数据集中异常定位图(对于每个类别,从左到右分别展示了原始图像、重建图像、真实缺陷标注图、输出缺陷标注图和异常定位图)

Fig.6 MMAERec anomaly localization maps in the MVTec AD dataset (for each category, the original image, the reconstructed image, the real defect labeling map, the output defect labeling map, and the anomaly localization map are shown from left to right)

在BTAD数据集上的实验对比结果如表4所示从表中结果可见,本方法的图像级和像素级平均AUC分别为90.1%和97%,在三个类别上均超过了其他的方法。与表现最好的PatchCore^[39]相比,MMAERec在图像级和像素级平均AUC上分别获得了0.1%和0.5%的领先。这主要是由于PatchCore依

赖于高质量预训练特征提取器,特征提取器的选择会影响所提取的特征质量,进而影响其检测性能。而本方法则只是将所提取的预训练特征用来辅助更新记忆模块,其并不参与图像检测过程,因此,检测性能不易受该因素的影响。同时,本方法在该数据集上所有类别的异常定位效果如图7所示。

表 4 在 BTAD 数据集上实验结果对比(AUROC %)
Table 4 Comparison of experimental results on the BTAD dataset(AUROC %)

方法	类别 1	类别 2	类别 3	平均
PatchCore ^[39]	90.9/95.5	79.9/94.7	99.8/99.3	90/96.5
SPADE ^[15]	91.4/97.3	71.4/94.4	99.9/99.1	87.6/96.9
P-SVDD ^[36]	95.7/91.6	72.1/93.6	82.1/91	83.3/92.1
Ours	95.5/97.6	75.6/93.9	99.2/ 99.4	90.1/97

(注：斜杠前为图像级 AUC，斜杠后为像素级 AUC)
(Note: image-level AUC before the slash, pixel-level AUC after the slash)




图 7 MMAERec 在 BTAD 数据集的异常定位图（01，02 和 03 表示该数据集的类别；对于每一个类别，从左到右为原始图像、重建图像、真实缺陷标注图、输出缺陷标注图和异常定位图）

Fig.7 MMAERec anomaly localization maps in the BTAD dataset (01, 02, and 03 denote the categories of this dataset; for each category, from left to right, are the original image, the reconstructed image, the real defects labeling map, the output defects labeling map, and the anomaly localization map)

4 讨论和消融实验

4.1 使用记忆增强模块和图像轮廓进行重建对模型性能的影响

本节主要探究所使用的多记忆模块和图像轮廓提取方法对网络模型性能的影响。我们分别探究了只使用多记忆增强模块、只使用图像轮廓以及两者的组合三种方法，从表 5 可得，仅使用记忆增强模块或图像轮廓进行重建的检测性能都小于两者结合后的模型检测性能。结合记忆增强模块和图像轮廓进行重建的性能比仅使用其中一个进行重建的方法在图像级平均 AUC 上能获得 31.2% 的最大提升，在像素级平均 AUC、平均 AP 和平均 PRO 最大提升分别为 22.8%，33.8%和 39.2%，这充分说明所提方法的有效检测性能。值得一提的是，在仅使用图像轮廓用于重建时，模型也能达到相对建好的性能，也说明本网络采用的提取图像轮廓方法的有效性。

表 5 记忆模块和图像轮廓对性能的影响（%）
Table 5 Impact of Memory Module and Image edge on Performance (%)

记忆提取 增强图像 模块轮廓	AUC-image	AUC-pixel	AUPRO	AP
✓	65.8	74.6	21.9	51.9
✓	92.8	94.2	51.3	82.6
✓	97	97.4	91.1	55.7

(注：在 MVTec AD 数据集上测试)
(Note: tested on MVTecAD dataset)

4.2 注意力模块对本网络模型性能的影响

进一步，我们讨论重建方法中常见的 CBAM、SE 和 CA 注意力模块对模型性能的影响。表 6 显示了不使用及使用不同注意力模块时模型的检测性能，相较于不使用注意力模块而言，使用 CBAM、SE 和 CA 注意力模块中任意一个，都能让模型在图像级平均 AUC、像素级平均 AUC、平均 PRO 和平均 AP 上分别提升最少 2.9%、2.9%、2.7%和 4%。这是由于在不使用注意力模块时，网络模型不能对融合后的特征进行有效的筛选和整合，使得特征信息存在冗余，

导致重建质量不佳而影响异常区域的定位。而相较于 CBAM 和 SE 注意力模块,使用 CA 注意力模块模型性能提升最大。在图像级平均 AUC、像素级平均 AUC、平均 AP 和平均 PRO 分别到达 97%、97.4%、55.7%和 91.1%,模型性能得到显著提高。这主要是因为 CA 注意力模块不仅能关注不同特征层上的信息,还能将特征层上的不同区域进行关联,使得关联后的特征信息更具有相关性和紧密型,其保留了更多重要特征信息,减少了特征冗余,有效提升图像的重建质量。而 SE 注意力模块通过对输入特征进行全

局平均池化,从通道域的角度赋予图像不同位置不同的权重,但由于只关注通道上特征信息,对空间上的信息并不能进行有效关注,使得融合的特征信息不能进行有效的关联。CBAM 注意力模块对输入特征先在通道上进行关注,再对空间进行关注,该操作虽然也能关注空间上的重要信息,但对于空间上的不同区域并不能进行有效关联,这会使得融合后的特征关联紧密性不高,使其仍然存在冗余信息,不利于重建。因此本文采用 CA 注意力模块对融合的特征实现有效关联。

表 6 各注意模块在 MVTec AD 数据集上的对比 (%)

Table 6 Comparison of Attention Modules on the MVTec AD Dataset (%)

CBAM ^[29]	SE ^[28]	CA ^[30]	AUC-image	AUC-pixel	AUPRO	AP
			92	91.1	80.5	49.4
✓			94.9	94.1	84.5	53.4
	✓		95.7	94	83.2	54
		✓	97	97.4	91.1	55.7

4.3 记忆库容量对模型性能的影响

记忆库容量大小对网络模型检测性能的影响。如图 8 所示,该折线图展示了记忆库中记忆项数量(即图 3 中 N 的值)分别为 10、20、30、40 和 50 时对应的检测性能,从中可看出,当记忆项个数从 10 到 30 时,对应的网络检测性能随记忆项个数增加而

增加,但当记忆项数量增加到 40 和 50 时,其检测性能随记忆项数量增加而下降。这是因为尽管使用阈值筛选操作处理记忆项,但仍会有小部分与正常相似的异常信息被保留。当记忆项数量增加时,所保留的异常信息会更多,使重建效果并不佳,从而导致模型检测性能下降。




图 8 记忆库中记忆项个数 N 对模型检测性能的影响Fig.8 Effect of the number of memory items N in the memory bank on the model detection performance

4.4 记忆模块的特征层层数组合对网络模型性能的影响

进一步, 记忆增强模块中所提取特征层层数组合对模型性能的影响。如表 7 所示, 表中展示了使用不同特征层的组合对模型性能的影响。当只考虑前四层时, 模型性能随着层数增加而提升。当提取

正常样本的前四个特征层作为记忆特征时, 模型能获得最佳性能。但提取前五个特征层作为记忆特征时, 模型性能有所下降。这主要是因为高层特征更偏向于预训练网络任务本身, 而中层和高层特征的结合更具有普适性。

表 7 不同层组合在 MVTEC AD 上的性能对比 (%)

Table 7 Performance comparison of different layer combinations on MVTEC AD (%)

性能指标	特征层层数组合				
	(1)	(1,2)	(1,2,3)	(1,2,3,4)	(1,2,3,4,5)
AUC-image	91.5	92.8	93.1	97	96.2
AUC-pixel	93.5	94.3	95.3	97.4	95.7
AUPRO	80.6	83.6	83.8	91.1	89.3
AP	46.1	50.3	51.7	55.7	52.5

4.5 不同损失函数组合对模型的影响

大多基于重建的方法都采用 l_2 损失或 SSIM 损失作为损失函数。为了让模型能更好地捕获图像的结构化信息, 我们将 l_2 损失和 SSIM 损失进行结合。同时, 为了有效提高记忆增强模块中权值 \hat{w} 的稀疏性, 本文在此基础上进一步引入 $Q_{(\hat{w})}$ 损失。我们分别探究了 l_2 损失、SSIM 损失、 l_2 损失和 SSIM 损失的组合以及它们分别与 $Q_{(\hat{w})}$ 损失的组合。如表 8 所示, 当 MMAERec 同时使用 l_2 损失和 SSIM 损失作为损失函

数时, 其检测性能大于仅使用 l_2 损失或 SSIM 损失时的性能, 在图像级平均 AUC、像素级平均 AUC、平均 AP 和平均 PRO 都获得了最少 1.5% 的提升。而在 l_2 损失、SSIM 损失、 l_2 损失和 SSIM 损失的组合基础上进一步引入 $Q_{(\hat{w})}$ 损失时, 其性能都得到了提升。当组合 l_2 损失、SSIM 损失以及 $Q_{(\hat{w})}$ 损失为最终损失函数时, 模型获得最优性能, 充分体现 $Q_{(\hat{w})}$ 损失的有效性, 证明所提损失函数的有效性。

表 8 不同损失函数在 MVTEC AD 上的性能对比 (%)

Table 8 Performance comparison of different loss functions on MVTEC AD (%)

l_2 -Loss	SSIM-Loss	$Q_{(\hat{w})}$ -Loss	AUC-image	AUC-pixel	AUPRO	AP
✓			90.1	92.5	83.2	50
✓		✓	91.3	92.7	85.1	50.2
	✓		92.7	93.3	83.4	51.2
	✓	✓	93.9	94.5	86.1	52.7
✓	✓		94.3	96.2	86.4	53.6
✓	✓	✓	97	97.4	91.1	55.7

4.6 推理速度


本节对 MMAERec 的推理速度进行了评估。具体来说, 将本方法与基于特征的方法 PaDim 和 SPADE 在推理速度上进行了对比。通过计算 PaDim、SPADE 和 MMAERec 在推理阶段的时间消耗, 得到

处理一张图像的时间分别为 0.319s、0.339s 和 0.115s。相比之下 MMAERec 的推理速度最快, 较于前两者而言, 本方法的推理速度提升了近 3 倍。我们还分别计算了 PaDim、SPADE 和 MMAERec 的参数量及计算量, 其参数量分别为 6.89M、7.35M 和 9.61M, 计

算量分别为 56.38GMac、59.96GMac 和 52.21GMac (Giga Multiply-Add Opreations Per Second, 每秒千兆乘法累加运算)。通过比较, 尽管 MMAERec 的参数量最大, 但其计算量都小于前两者, 且推理速度最快, 使得本方法在推理速度上具有一定的竞争优势, 验证了所提方法网络架构的有效性。


4.7 参数选择

本节主要对公式(6)中参数 θ 和 α 的选择进行实验验证。我们分别对 θ 的常用取值 0.5、0.6、0.7、0.8、0.9、1、1.1、1.2、1.3、1.4、1.5 以及 α 的常用取值 0.0001、0.00012、0.00014、0.00016、0.00018、0.0002、0.00022、0.00024、0.00026、0.00028、0.0003 进行相关实验验证, 如图 9 中(a)和(b)分别展示了 θ 和 α 取不同值时对应的性能指标变化。在(a)中, 我们对比了其图像级平均 AUC(左上)、像素级平均 AUC(右上)、平均 AP(左下)和平均 PRO(右下)的变化, 从中可知, 当 $\theta=1$ 时, 模型性能为最佳。且都领先于其他选值所对应的检测指标; 同样的, 从(b)中可得, 当 α 为 0.0002 时所对应的性能指标为最好, 且都优于其他选值对应实验结果。通过 θ 和 α 不同选值的实验结果, 充分验证了所选参数的可靠性。



(a) θ 取不同值时对应的性能指标变化

(a) θ changes in performance indicators for different values



(b) α 取不同值时对应的性能指标变化

(b) α changes in performance indicators for different values

图 9 参数 θ 和 α 的选择对模型检测性能的影响

Fig.9 The effect of the choice of parameters θ and α on the detection performance of the model

5 结论

本文提出了一种新的重建模型, 从缓解过度泛化问题和提高重建图像质量两个方面提高异常检测性能。具体来说, 我们引入多记忆增强模块, 该模块在训练过程只学习正常样本数据分布, 且在提取到输入图像的多尺度特征进行处理时, 得到的记忆特征更符合正常样本特征。利用处理得到记忆特征进行重建能让模型对正常区域进行很好重建, 而不能很好重建异常区域, 有效缓解过度泛化问题。其次, 我们在记忆特征的基础上进一步结合了图像轮廓特征, 因为提取到的图像轮廓特征保留了重要的原始高频分量, 这很好缓解了重建图像轮廓模糊的问题, 有效提高重建图像质量。利用这两种不同特征的融合进行重建, 使得重建图像更加真实、全面和完整。最后, 进一步引入关于颜色的评价函数使得模型对图像异常的定位更加准确, 有效提升了模型检测性能。

参考文献:

- [1] Zhang F, Kan S, Zhang D, et al. A graph model-based multiscale feature fitting method for unsupervised anomaly detection[J]. Pattern Recognition, 2023, 138:109373.
- [2] Zhang, L, Kan, S, Cen, Y, et al. A Normalizing Flow-Based Bidirectional Mapping Residual Network for Unsupervised Defect Detection. Computers, Materials & Continua, 2024, 78(2):1631-1648.
- [3] 张兰尧, 陈晓玲, 张达敏, 等. ValidFlow: 基于标准化流的无监督图像缺陷检测. 数据采集与处理, 2023, 38(6): 1445-1457.

- ZHANG L, CHEN X, ZHANG D, et al. ValidFlow: Unsupervised Image Defect Detection Based on Normalizing Flows. *Journal of Data Acquisition and Processing*, 2023, 38(6): 1445-1457.
- [4] DEFARD T, SETKOV A, LOESCH A, et al. Padim: a patch distribution modeling framework for anomaly detection and localization; proceedings of the International Conference on Pattern Recognition, F, 2021: 475-489.
- [5] ZHOU Y, XU X, SONG J, et al. MSFlow: Multiscale Flow-Based Framework for Unsupervised Anomaly Detection [J]. 2024: 1-14
- [6] COHEN N, HOSHEN Y J A P A. Sub-image anomaly detection with deep pyramid correspondences[J]. (2020-5-5).
- [7] WANG G, HAN S, DING E, et al. Student-teacher feature pyramid matching for anomaly detection[J]. (2021-3-7).
- [8] YANG J, SHI Y, QI Z J A P A. Dfr: Deep feature reconstruction for unsupervised anomaly segmentation[J]. (2020-12-3).
- [9] GONG D, LIU L, LE V, et al. Memorizing normality to detect anomaly: Memory-augmented deep autoencoder for unsupervised anomaly detection; proceedings of the Proceedings of the IEEE/CVF international conference on computer vision. 2019 : 1705-1714.
- [10] YAMADA S, KAMIYA S, HOTTA K. Reconstructed student-teacher and discriminative networks for anomaly detection; proceedings of the 2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). IEEE, 2022: 2725-2732.
- [11] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.
- [12] Liu T, Li B, Zhao Z, et al. Reconstruction from edge image combined with color and gradient difference for industrial surface anomaly detection[J]. arXiv preprint arXiv:2210.14485, 2022.
- [13] Bergmann P, Fauser M, Sattlegger D, et al. MVTec AD--A comprehensive real-world dataset for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9592-9600.
- [14] Mishra P, Verk R, Fornasier D, et al. VT-ADL: A vision transformer network for image anomaly detection and localization[C]//2021 IEEE 30th International Symposium on Industrial Electronics (ISIE). IEEE, 2021: 01-06.
- [15] Ruff L, Vandermeulen R, Goernitz N, et al. Deep one-class classification[C]//International conference on machine learning. PMLR, 2018: 4393-4402.
- [16] Bergman L, Hoshen Y. Classification-based anomaly detection for general data[J]. arXiv preprint arXiv:2005.02359, 2020.
- [17] Rippel O, Mertens P, Merhof D. Modeling the distribution of normal data in pre-trained deep features for anomaly detection[C]//2020 25th International Conference on Pattern Recognition (ICPR). IEEE, 2021: 6726-6733.
- [18] Zavrtanik V, Kristan M, Skočaj D. Reconstruction by inpainting for visual anomaly detection[J]. *Pattern Recognition* 2021, 112: 107706
- [19] Bergmann P, Löwe S, Fauser M, et al. Improving unsupervised defect segmentation by applying structural similarity to autoencoders[J]. arXiv preprint arXiv:1807.02011, 2018.
- [20] Collin A S, De Vleeschouwer C. Improved anomaly detection by training an autoencoder with skip connections on images corrupted with stain-shaped noise[C]//2020 25th International Conference on Pattern Recognition (ICPR). IEEE, 2021: 7915-7922.
- [21] Venkataramanan S, Peng K C, Singh R V, et al. Attention guided anomaly localization in images[C]//European Conference on Computer Vision. Cham: Springer International Publishing, 2020: 485-503.
- [22] Liang Y, Zhang J, Zhao S, Wu R, Liu Y & Pan S. Omni-frequency channel-selection representations for unsupervised anomaly detection. *IEEE Transactions on Image Processing*. 2003, 32: 4327-4340.
- [23] Schlegl T, Seebock P, Waldstein S M, et al. f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks[J]. *Medical image analysis*, 2019, 54: 30-44.
- [24] Mei, S, Yang, H, & Yin, Z. An unsupervised-learning-based approach for automated defect inspection on textured surfaces. *IEEE transactions on instrumentation and measurement*, 67(6), 2018, 1266-1277.
- [25] Kang G, Gao S, Yu L, et al. Deep architecture for high-speed railway insulator surface defect detection: Denoising autoencoder with multitask learning[J]. *IEEE Transactions on Instrumentation and Measurement*, 2018, 68(8): 2679-2690.
- [26] Golan I, El-Yaniv R. Deep anomaly detection using geometric transformations[J]. *Advances in neural information processing systems*, 2018, 31.
- [27] Ye F, Huang C, Cao J, et al. Attribute restoration framework for anomaly detection[J]. *IEEE Transactions on Multimedia*, 2020, 24: 116-127.
- [28] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. *IEEE transactions on image processing*, 2004, 13(4): 600-612.
- [29] Zavrtanik V, Kristan M, Skočaj D. Reconstruction by inpainting for visual anomaly detection[J]. *Pattern Recognition*, 2021, 112: 107706.
- [30] Bergmann P, Fauser M, Sattlegger D, et al. Uninformed students: Student-teacher anomaly detection with discriminative latent embeddings[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 4183-4192.
- [31] Hu J, Shen L, Sun G. Squeeze-and-excitation networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 7132-7141.
- [32] Fukui H, Hirakawa T, Yamashita T, et al. Attention branch network: Learning of attention mechanism for visual explanation[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 10705-10714.
- [33] Hou Q, Zhou D, Feng J. Coordinate attention for efficient mobile network design[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 13713-13722.
- [34] Shi Y, Yang J, Qi Z. Unsupervised anomaly segmentation via deep feature reconstruction[J]. *Neurocomputing*, 2021, 424: 9-22.
- [35] Schlüter, H M, Tan, J, Hou, B & Kainz, B. Self-supervised out-of-distribution detection and localization with natural synthetic anomalies (nsa). 2021, arXiv preprint

- arXiv:2109.15222, 2(5).
- [36] Yi J & Yoon S. Patch svdd: Patch-level svdd for anomaly detection and segmentation. In Proceedings of the Asian conference on computer vision. 2020.12672:375-390.
- [37] Pirnay J, Chai K. Inpainting transformer for anomaly detection[C]//International Conference on Image Analysis and Processing. Cham: Springer International Publishing, 2022: 394-406.
- [38] Hou J, Zhang Y, Zhong Q, et al. Divide-and-assemble: Learning block-wise memory for unsupervised anomaly detection[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 8791-8800.
- [39] Roth K, Pemula L, Zepeda J, et al. Towards total recall in industrial anomaly detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 14318-14328.