

doi:10.3969/j.issn.1003-3106.2024.11.010

引用格式:高静,冯金顺,董少然,等.小样本深度学习在目标识别分类领域的应用前景研究[J].无线电工程,2024,54(11):2594-2601.[GAO Jing, FENG Jinshun, DONG Shaoran, et al. Research on Application Prospects of Few-shot Deep Learning in Object Recognition and Classification Field [J]. Radio Engineering, 2024, 54(11): 2594-2601.]

小样本深度学习在目标识别分类领域的应用前景研究

高 静¹, 冯金顺¹, 董少然¹, 郭新苍¹, 范烁晨¹, 赵乾宏², 朱光耀¹, 陈家良¹, 马胤焱¹

(1. 中国电科网络通信研究院, 河北 石家庄 050081;

2. 中国卫星海上测控部, 江苏 江阴 214431)

摘 要:近年来,深度学习技术在大数据训练模型上取得了显著成就。但由于领域的特殊性,很难获取到大量标注/无标注样本,人工标注数据会耗费大量的人力,限制了其在该领域的应用和推广。而小样本目标识别分类只需要少量的标注样本数据,即可实现在有限样本条件下对典型目标的识别分类。以目标识别分类为主要应用领域,对基于数据增强、迁移学习和度量学习3种常用的提升小样本目标识别分类性能算法的研究现状进行了介绍,并阐述了算法的优缺点。对小样本学习仍旧面临的一些挑战和未来研究方向的展望进行了梳理和总结。

关键词:小样本目标识别分类;数据增强;迁移学习;度量学习

中图分类号: TP18

文献标志码: A

开放科学(资源服务)标识码(OSID):



文章编号: 1003-3106(2024)11-2594-08

Research on Application Prospects of Few-shot Deep Learning in Object Recognition and Classification Field

GAO Jing¹, FENG Jinshun¹, DONG Shaoran¹, GUO Xincang¹, FAN Shuochen¹, ZHAO Qianhong²,
ZHU Guangyao¹, CHEN Jialiang¹, MA Yinyao¹

(1. Academy for Network & Communications of CETC, Shijiazhuang 050081, China;

2. China Satellite Maritime Tracking and Control Department, Jiangyin 214431, China)

Abstract: In recent years, deep learning technology has made remarkable achievements in big data training models. However, due to the particularity of the field, it is difficult to obtain a large number of labeled/unlabeled samples. And manual annotation of data will consume a lot of manpower, limiting its application and promotion in this field. Few-shot object recognition and classification only requires a small amount of labeled sample data to achieve the recognition and classification of typical objects under limited sample conditions. Taking recognition and classification as the main application field, the research status of three commonly used algorithms for improving the performance of few-shot object recognition and classification based on data enhancement, transfer learning and metric learning is introduced and the advantages and disadvantages of these algorithms are elaborated. Finally, some challenges still faced by few-shot learning and prospects for future research directions are sorted out and summarized.

Keywords: few-shot object recognition and classification; data augmentation; transfer learning; metric learning

0 引言

快速准确实现目标识别分类是信息化战争背景下的迫切需求,直接影响到效能。迄今为止,目标识别领域主要基于传统的人工特征设计、提取,基于自动化提取目标特征的深度学习算法成为目前目标识别分类商业化应用发展阶段中被期望克服数据专业性壁垒、数据处理耗时长等困难的一种方式^[1]。随着大数据技术的发展,以深度学习算法为主实现的机器

学习技术在目标识别分类领域取得了革命性的飞跃,检测的精度和性能均得到了明显的提升,广泛应用于实际场景中。但是深度学习目标检测模型的建立对样本数量和数据质量的依赖性较高,由于领域和任务的特殊性,能够获取到的数据量往往不充足^[2],在没有大量高质量数据的支持下,如何获得较好的检测效果并更好地应用于相关领域,基于小样本的深度学习算法的研究与应用成为人工智能领域的研究热点。

收稿日期:2024-01-15

小样本学习^[3]旨在利用先验知识克服海量数据缺失带来的模型过拟合问题,提高模型在新类别上的泛化能力,极大程度降低数据集获取建立的成本和难度^[4]。本文以小样本学习为主要研究内容,简述了小样本学习的基本理论,探讨了基于数据增强、迁移学习及度量学习³种常用方法在目标分类识别领域的应用场景和现状,分析了目前小样本目标分类识别方案在该领域仍旧存在的问题,给出了未来研究、应用的展望,以为小样本学习在目标识别分类领域的探索与发展提供更多有益的参考。

1 基于小样本的深度学习

机器学习模型建立的一般流程为:①标注、获取数据集;②初始化模型参数;③模型训练与调优。模型 $M(x)$ 的训练过程是为了拟合数据的真实分布,但在传统目标识别分类应用中,由于复杂因素的限制,真实模型往往难以建立,数据的真实分布 $p(x, y)$ 也不可不知,所以训练模型与实际往往存在误差,这个误差称为期望风险:

$$R(M) = E[M(x), y] = \int l(M(x), y) dp(x, y)。 \quad (1)$$

通常情况下,使用在训练数据集上模型预测的结果和真实结果的差异作为模型的评价指标,这个差异来源于拟合分布误差和模型训练误差,当差异最小时,即为获取的最终训练模型^[5],差异函数为:

$$E(M) = \frac{1}{n} \sum_{i=1}^n l(M(x_i), y_i), \quad (2)$$

式中: n 为样本数量, $M(x_i)$ 为训练模型的预测值, y_i 为真实值。

因此,上述误差可以分解为:

$$\begin{aligned} E(M) &= E[R(M_{\text{train}}) - R(M_{\text{real}})] = \\ &E[R(M_{\text{train}}) - R(M_{\text{distribution}})] + \\ &E[R(M_{\text{real}}) - R(M_{\text{distribution}})]。 \end{aligned} \quad (3)$$

当样本数量 n 足够多时:

$$\lim_{n \rightarrow \infty} [R(M_{\text{train}}) - R(M_{\text{distribution}})] = 0。 \quad (4)$$

当具有标注信息的样本数量足够时,模型训练误差就会变小,如图1(a)和图1(b)所示。但在小样本目标识别分类应用中,模型训练误差往往都较大。因此,在样本数量较少时,采用传统的训练模型算法是很难获得满意的精度的,需要探索新的解决方案。人类的一个突出特征是通过一定的知识学习与积累,只学习少量乃至单个实例即可实现对新物体的识别与分类。受此启发,在深度学习发展基础之上,提出了利用之前学习的先验知识辅助模型训练学习降低模型训练误差的小样本学习的概念,如图1(c)所示,小

样本学习的核心就是在小样本条件下降低模型的训练误差。

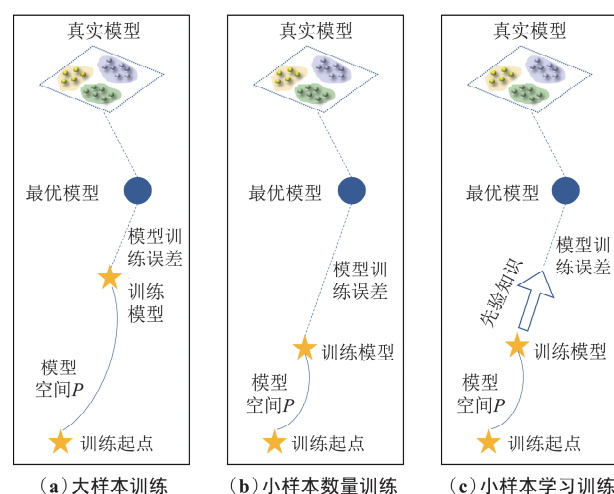


图1 模型训练过程

Fig.1 Model training process

小样本学习的定义是从某个类的包含有限信息的样本集中学习出该概念类。基于小样本的深度学习通常将数据集划分为训练集(Training Set)、支持集(Support Set)和查询集(Query Set)三部分。其中,训练集是用于预训练学习模型的源数据集,一般包含了大量的标记信息;支持集是用于选出具有优良分类性能模型的目标域训练数据集,包含了少量的标记信息;查询集是用于验证训练模型准确率的目标域测试数据集。但有别于传统的分类算法,在小样本学习中,这3个数据集包含的类别是完全不同的。在每个给定的元任务中,支持集与查询集包含相同的标签集,但二者随机选取不重复数据样本。支持集是由具有标记信息的样本组成,与传统目标识别分类模型建立的“训练集”类似,使模型学习不同任务之间的共性部分;查询集是由无标记信息的样本组成,与传统目标识别分类模型建立的“测试集”类似,用于测试学习模型的准确率。

整个小样本学习由多个片段式子任务组成,且子任务之间都是相互独立的。一般情况下,给定一个子任务 T , T 包含了 N 类数据样本,在每个样本类别中均随机抽取 k 个样本,通常 k 是一个很小的数,最终在训练阶段构成了 $k \times N$ 大小的支持集;在 N 类数据样本的剩余样本中随后抽取部分样本构成查询集,通过支持集样本数据使得模型在查询集的准确率得到提高,将这样的支持集所构建的任务称为 N -way k -shot。小样本学习使用episode策略进行训练,训练过程中会分为若干个episodes,每个episode即为基于划

分的支持集 $S = \{(x_i, y_i)\}_{i=1}^{k \times N}$ 和查询集 $Q = \{(x_j, y_j)\}_{j=1}^q$ 进行训练,更新梯度并计算损失误差。

2 深度学习中小样本建模机制的应用

目前,小样本学习领域有几种常用处理各类应用场景的建模方法,分别为基于数据增强的方

法、基于迁移学习的方法以及基于度量学习的方法等。对传统目标识别分类算法与小样本学习的几种方法进行了简要的对比分析,如表 1 所示。接下来就小样本学习的 3 种方法在雷达目标识别、遥感目标检测和实体识别等领域的研究现状进行详细介绍。

表 1 传统目标识别分类算法与基于小样本的深度学习算法对比分析

Tab.1 Comparative analysis of traditional object recognition and classification algorithms and few-shot sample-based deep learning algorithms

分类	应用场景	模型方法	优点	缺点
传统目标识别分类算法	需要大量样本和较多的计算资源	Adaboost ^[6]	有效捕捉局部特征信息,提高模型的精度	模型的扩展性和泛化能力较差
		HOG ^[7]		
		DPM ^[8]		
		ResNet ^[9]		
基于数据增强的算法		GAN ^[10]	实现较为容易,可叠加多种增强手段;利用辅助数据或者辅助特征进行样本扩充实现性能提升	性能提升效果有限,需要进行大量计算,存在引入噪声数据产生负面影响的可能
		DAGAN ^[11]		
		Δ -encoder ^[12]		
基于小样本的深度学习 目标识别分类算法	基于迁移学习的方法	TransMatch ^[13]	检测精度相对较高,学习策略简单,模型泛化能力强	易出现过拟合,不适用实时检测
		FSCN ^[14]		
		LSTD ^[15]		
		TFA ^[16]		
	基于度量学习的方法	匹配网络 ^[17]	便于计算和公式化,容易实现增量学习	在样本数量较少的情况下,简单通过距离衡量相似度的方法准确率会有所降低
		关系网络 ^[18]		
		DSN ^[19]		

2.1 基于数据增强的小样本目标识别分类

数据增强,也可称为数据扩充,是一种通过算法基于已有数据自动生成等价新数据的技术,能达到扩充训练集的目的。该方法能够不增加人工标注数据的工作,自动生成大量数据集,增强数据集的体量与多样性,从而避免学习模型过度拟合的问题。数据增强的方法分为数据合成和特征增强法。在传统的图像分类领域,常见的数据增强方法是使用旋转、几何变换和随机擦除等操作在原有图像基础上进行数学变换以实现数据扩充,而特征增强法则可借助一些辅助信息进行增强操作。随着对数据增强的深入研究,生成对抗网络(Generative Adversarial Network, GAN)^[20]模型被提出,该模型是数据增强算法框架中较有代表性的一种,由生成器和判别器两部分组成,生成器的目标是不断生成变化的以假乱真的新样本,而判别器的目标则是判断生成的新样本的真假,通过二者的不断迭代和博弈学习,将目标识别分类任务转化为多个单目标函数优化组合问题,

生成拟合真实数据分布的有变化的模拟数据,算法伪代码如算法 1 所示。

算法 1 GAN 模型的训练过程

输入:训练集 D ,生成器训练次数 T ,判别器训练次数 K ,小样本数量 M
输出:GAN 模型 $G(z; \theta)$
随机初始化模型参数 θ, ϕ ;
for T steps do
for K steps do
从 D 中采集 m 个样本 $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}, 1 \leq m \leq M$;
从服从 $p_g(z)$ 分布的噪声数据中采集 m 个样本 $\{z^{(1)}, z^{(2)}, \dots, z^{(m)}\}, 1 \leq m \leq M$;
通过随机梯度上升,更新 ϕ :
$\frac{\partial}{\partial \phi} \left[\frac{1}{m} \sum_{i=1}^m (\log D(x^{(i)}; \phi) + \log(1 - D(G(z^{(i)}; \theta); \phi))) \right]$
end
从服从 $p_g(z)$ 分布的噪声数据中采集 m 个样本 $\{z^{(1)}, z^{(2)}, \dots, z^{(m)}\}, 1 \leq m \leq M$;
通过随机梯度上升,更新 θ :
$\frac{\partial}{\partial \theta} \left[\frac{1}{m} \sum_{i=1}^m D(G(z^{(i)}; \theta); \phi) \right]$
end

在 GAN 的发展基础之上,陈龙等^[21]设计了一种基于 GAN 优化样本数据质量与深度森林学习模型^[22]相结合的方法实现图像中目标的智能识别,该方法采用了多粒度特征提取,无需人工耗时干预特征选择。分别采用 GAN 和传统模型增强方法对初始目标样本和优化后的目标样本进行了扩展,最大程度上生成与真实样本相似的数据,通过增加高质量数据样本量解决模型在小样本条件下的收敛问题,构建了具有强鲁棒性的网络模型,提升了目标识别的准确率,优于其他许多算法。Jiang 等^[23]针对小样本条件下深度学习网络模型产生的过拟合影响遥感图像目标检测精度的问题,提出了基于风格迁移的数据增强方法,利用基于特征提取、激活函数以及损失函数改进的循环 GAN (Cycle GAN)^[24]获取新数据,改进的模型采用了在不同层级的网络之间添加特征扰动,将风格损失加入了损失函数表征不同自然季节、环境等方法,相较于原 Cycle GAN 加强了数据集之间的一致性控制,模型训练结果表明,将扩充的数据集加入原始数据集后,目标检测和识别的准确性得到了提高。王亦倩^[25]采用了深度 GAN 与舰船三维模型电磁仿真信息结合的方法生成样本进行扩充,扩充的舰船雷达图像比传统方法扩充的样本质量和多样性均得到了明显的提升,建立基于回归的端到端的目标检测识别模型,提高了小样本条件下模型的检测识别准确度和泛化能力。

在自然语言处理领域中,由于其离散抽象的特点,微小的差异即可影响最终的语意表达。而由于领域本身的独特性,对专属于小样本命名实体识别的研究十分缺少。刘兴丽等^[26]提出一种基于简单数据增强 (Easy Data Augmentation, EDA) 算法^[27]面向小样本命名实体识别的数据增强多维改进策略,即基于人工标注的小样本数据集、半自动化构建的实体以及开源的武器信息实体集构成的领域词典进行实体替换、词性替换等,从根本上解决了样本稀疏问题,最终验证单策略 EDA 改进的提升效果显著。

总而言之,数据集的真实分布通常情况下都是不可知的,数据增强的解决方案也只是对原始数据集的绝对近似,受限于模型实现的效果及样本数据中的错误标注信息等,有可能造成数据的负向偏移。但数据增强仍旧是小样本条件下有效提升目标识别分类效果的有效手段。

2.2 基于迁移学习的小样本目标识别分类

迁移学习旨在将与新的领域(目标域)具有相似规律可循的现有领域(源域)知识迁移至目标域,

同时辅助目标域的学习任务。通常情况下,为了获取性能优异的学习模型,往往需要根据样本标签数据的变化,重新建立模型、训练超参数,而基于小样本的迁移学习思想恰好可以用来解决此类问题,如图 2 所示。




图 2 迁移学习模型示意

Fig. 2 Schematic diagram of transfer learning model

除此之外,迁移学习相较于传统的机器学习算法放宽了训练样本数据和测试样本数据服从相同概率分布的限制,一般情况下,源域和目标域的概率分布为 $P_S(x, y) \neq P_T(x, y)$, 其中, P_S 是源域的概率分布, P_T 是目标域的概率分布。

迁移学习方法根据迁移内容的不同可以分为 4 类:实例迁移学习方法、关系迁移学习方法、模型迁移学习方法和特征迁移学习方法,但都可统一表征为:

$$f = \underset{f \in H}{\operatorname{argmin}} \frac{1}{N_S} \sum_{i=1}^{N_S} l[v_f(x_i), y_i] + \lambda R[T(D_S), T(D_T)], \quad (5)$$

式中: N_S 表示源域的样本数量, v_i 表示源域中样本 x_i 的权重, T 表示目标域和源域上的特征迁移函数, $R(\cdot)$ 表示正则化项。不同类迁移学习方法适用于不同的应用场景,其分析比较如表 2 所示。

胡安林^[28]基于特征迁移学习方法引入了一种采用竞争策略的自适应微调网络模块,改进了卷积神经网络 VGG-16^[29] 和 GoogLeNet^[30] 并进行预训练。随后将预训练模型迁移到训练舰船目标样本数据的 Faster R-CNN^[31] 和 YOLO^[32] 网络,解决了小样本下舰船目标检测的过拟合和性能过低等问题,并通过实验验证了提出方法的有效性。郭继光等^[33]提出了一种基于不同深度的神经网络模型和特征迁移学习的跨域小样本目标识别方法,基于成熟的深度学习模型获取泛化能力较强的特征表达,通过提取真实样本与拟合样本的特征对源域和目标域之间的关系进行了描

述,综合了2种学习方法,利用CATIA建模实验对模型进行验证分析,对比了不同网络结构、数据特征,最终获取了双向长短记忆神经网络在小样本弹道导弹目标识别过程中具有较好的识别准确率。王美玉等^[34]探索了一种基于迁移学习的小样本条件下进行电磁目标精确识别的方法,其中包括同类目标迁移和异类目标迁移,在同类源样本减少4/5的情况下,相较于非迁移模型识别率得到了有效提升;在异类源极

少样本的情况下,在保证识别率的同时提高了模型性能。领域业务数据爆炸式增长,文本大量存在并被使用,从其中自动化提取系统相关的关键信息并加以归类成为一个亟待解决的问题。徐建等^[35]提出了一种基于领域迁移和任务迁移相结合的小样本文本命名实体识别方法,且采用了基于实体替换和伪标签等数据增强方法,有效地提升了小样本情况下模型对命名实体识别的准确率。

表2 不同迁移学习方法对比分析

Fig.2 Schematic diagram of transfer learning model

类别	分类	主要思想	应用场景	优点	缺点
实例迁移学习方法		根据相似度匹配原则,从源域中选出和目标域中关联性强的样本迁移到目标域中,辅助目标域中模型训练	源域与目标域样本存在相同特征	实现简单,解决目标域中标签样本量不足/无标签样本的学习问题	限制源域和目标域样本有重叠特征
特征迁移学习方法	数据层面	利用算法模型在源域和目标域之间识别共有特征,实现知识模型的迁移	源域与目标域样本差异极大	解决模型跨域学习的问题,训练速度相对较快	不同特征迁移模型具有任务和特征的特殊性,可移植性较低
关系迁移学习方法		源域和目标域样本间存在一定的相关性,通过建立关系映射模型实现迁移	源域与目标域样本差异较大	降低了源域和目标域样本之间的强依赖性	训练过程较为困难
模型迁移学习方法	模型层面	通过源域中大量样本训练好的模型迁移到目标域上进行应用	源域与目标域有共享参数	具有较高的精度	模型不易收敛,要求源域和目标域样本相似,易造成负迁移

迁移学习可以较好地提升网络模型的泛化能力,实现训练过程中的参数和特征迁移,但极易丢失积累的经验信息,造成严重的过拟合问题。同时,迁移学习受数据集复杂度的影响较大,普适性不足。

2.3 基于度量学习的小样本目标识别分类

度量学习即相似度学习,旨在学习一个嵌入空间,将输入样本特征映射到相同的高维空间,利用目标函数获取潜在目标区域特征,使同一类别样本更加接近,不同类别样本远离。最后,模型根据嵌入空间中特征间进行相似性度量计算距离分布,将样本划分到正确类别中去,模型示意如图3所示。由于模型会根据样本之间的相似度大小判断样本的类别,因此距离度量函数的确定就尤为重要,常见的有欧式距离、曼哈顿距离和余弦相似度等。最为经典的度量学习模型包括匹配网络(Matching Network)、原型网络(Prototypical Network)^[36]和关系网络(Relation Network)模型3种,其中,匹配网络和原型网络都是基于距离度量函数计算样本间的相似度,但是距离度量并不适用于所有任务。为了解决此类情况,关系网络采用了深度神经网络进行度量,其分为嵌入和关系2个模块,嵌入模块用于实现样本到特

征空间的映射,关系模块用于比较计算样本间的相似度,具体算法流程为:对于给定的样本 x_i 和输入的新样本 x_j ,对于每一组 (x_i, x_j) ,通过嵌入模块产生一组 $f_\varphi(x_i), f_\varphi(x_j)$ 映射关系,通过 $C(\cdot, \cdot)$ 进行深度特征组合获取 $C(f_\varphi(x_i), f_\varphi(x_j))$ 。随后,将深度特征组合向量输入到关系模块 g_ϕ 中,计算得出 x_i 和 x_j 之间的关系得分,表征样本之间的相似度、获得分类结果,如下式所示:

$$r_{i,j} = g_\phi(C(f_\varphi(x_i), f_\varphi(x_j))), i = 1, 2, \dots, N. \quad (6)$$

随着度量学习的发展,后续又有许多网络被研究者提出。




图3 度量学习模型示意

Fig.3 Schematic diagram of metric learning model

刘旗等^[37]提出了一种基于门控多尺度匹配网络的小样本合成孔径雷达 (Synthetic Aperture Radar, SAR) 目标识别方法, 解决领域探测 SAR 图像数量不足条件下准确识别的问题, 引入多尺度特征提取模块以提取匹配网络不同卷积层的多尺度特征, 根据不同的识别任务, 权重门控单元能够赋予不同卷积层特征不同的权重, 以任务为主导选择最具代表性的目标特征完成识别任务, 识别准确度和稳定性都得到了提升。金璐等^[38]提出了一种基于关系网络模型、多尺度特征融合方法及元学习训练策略结合的小样本红外空中目标分类方法, 利用构造的多尺度特征提取模块提取输入样本的特征信息, 通过关系模块计算支撑样本集和预测样本集的关系值, 根据关系值输出预测样本的类别标签, 该方法具有较好的分类效果, 为小样本空中目标分类在电子侦察领域的应用提供了一种途径。孟浩等^[39]为解决船舶目标样本数量不均衡导致的过拟合问题提出了一种跨目标通用全局注意力机制 (Global Attention Mechanism, GAM)^[40]与关系度量网络结合的目标识别算法, 通过关系网络提取到样本集的原始特征信息, 利用全局注意力机制在支持集、查询集的特征提取过程中减轻不均衡类别、样本及特征的过拟合现象, 随后与原始特征信息融合进行特征距离度量。该方法提升了目标样本特征分布比例, 有利于减少假正样本特征信息, 提升了小样本小标签情况下的船舶目标识别精度。

度量学习原理简单、训练开销小, 更容易实现增量式学习, 即模型完成训练后无需从头训练模型参数就可直接用于小样本的新类别目标检测。虽然度量学习在小样本目标识别分类领域取得了一定的成果, 但还存在着一些缺陷: ① 对采集的样本集的依赖性较高, 受限于样本集的复杂度, 可能产生过拟合或不会学习对目标识别分类有用的信息; ② 未将噪声干扰对小样本目标分类结果的影响考虑在内; ③ 采用全局特征度量样本间的差异, 对目标类别分布表达不充分。

2.4 数据集与实验

目标识别领域中, 常用基于标准数据集 Omiglot、Mini-ImageNet 及 Tiered-ImageNet 等获得的实验结果作为评估训练模型性能的指标。

本文选取了一些应用于目标分类识别领域的典型模型在 Omiglot 和 Mini-ImageNet 数据集上的实验结果进行对比参考, 如表 3 所示, 此处采用了 5-way 1-shot 和 5-way 5-shot 的实验结果 (以准确率百分比

表示)。可以看出, 2 个数据集中 5-shot 的识别精度均明显高于 1-shot, 在 Omiglot 数据集上, 模型准确率都较高, 而在 Mini-ImageNet 数据集上, 模型最高准确率仅可提升到 70%~80%, 因此可与其他网络模型组合进一步提高在该数据集上的分类识别准确率。

表 3 目标识别分类算法准确率对比

Tab. 3 Comparison of accuracy of object recognition and classification algorithms

单位: %

方法	Omiglot		Mini-ImageNet	
	5-way	1-shot	5-way	5-shot
△-encoder	—	—	59.90	69.70
TransMatch	—	—	62.93±1.11	82.24±0.59
匹配网络	98.10	98.90	46.60	60.00
原型网络	98.80	99.70	49.42±0.78	68.20±0.66
关系网络	99.60±0.20	99.80±0.10	50.44±0.82	65.32±0.70

3 主要挑战与未来发展

信息化的重要性是不可忽视的。现代信息技术的发展, 能够提供多元化的监视、探测和信息跟踪, 能够有效获取地方战场情报, 洞察地方配置和战略部署, 为战争指挥者提供重要的信息参考, 打破地方战场盲区, 运用新型方式, 以更小的战争成本取得胜利。

人工智能技术正在加速发展, 快速准确进行目标识别分类可能会深刻影响未来战争的制胜机理和方式。自二十世纪中期, 国外目标识别技术就已经开始发展, 相比于国外, 我国开展相关技术研究的时间较晚, 二十世纪八九十年代以后, 随着硬件条件的大跨步提升, 国内许多研究单位进行了深入探索, 深度学习被广泛应用于领域。但由于样本数量少、识别模型精度高, 基于小样本的深度学习技术得到了迅速发展, 主要应用于高分辨雷达一维距离像、SAR 图像目标识别以及图像处理等方面, 对目标识别准确度与稳定性带来的提升进行了有效验证。

但由于应用场景的复杂性, 目前仍处于算法仿真测试阶段, 还未与武器装备、指挥控制系统等融合, 所以仍旧面临着许多挑战: ① 泛化能力相较于海量样本集目标识别分类性能有较大差距, 目前还难以满足实际应用需求, 不便于领域不同场景、分支的迁移应用; ② 现有的小样本识别分类算法主要解决同域不同类或同类不同域的问题, 目前还没有解决不同类不同域的合适策略, 海、陆、空三大类目标

识别分类各有独特的技术难点,迁移成熟的模型解决复杂问题十分困难;③小样本深度学习算法可解释性较弱,在基于迁移学习的小样本目标识别分类模型中,特征、参数迁移的保留很难确定,尤其是复杂战场环境下信息的高模糊性与欺骗性,导致识别分类过程难以理解;④基于小样本的目标识别分类算法的应用目前还集中于舰船等遥感图像目标检测识别方向。

通过对当前基于小样本深度学习的目标识别分类应用与研究进展的梳理,可在以下方面展望:

①通过改善学习模型、研究轻量化的网络模型,减少模型训练时间,降低对计算、存储资源的消耗,进一步提高模型的泛化能力和识别精度,尽可能满足领域应用高实时性的要求;②为了更好地理解模型适合被迁移的特征和参数,探索提高模型在领域应用可解释性的方法;③聚焦于降低对样本数据量的依赖实现高性能高精度的大规模小样本算法,大规模小样本学习任务主要解决海量类别的图像分类,但每个类别仅包含极少量的样本标记数据;④可进一步扩展算法在领域内命名实体分类、电磁目标识别的应用。

4 结束语

本文主要对基于小样本深度学习的目标识别分类领域的应用研究现状做了详细介绍,即基于数据增强、迁移学习和度量学习3种常用的提升小样本目标识别分类性能的算法,并阐述了3种算法的优缺点。最后,提出了小样本目标识别分类在领域应用仍旧面临的一些挑战和对未来研究方向的展望。本文指出了小样本学习目前还未部署于系统、未与实际紧密结合,针对领域的特殊性,需要研究实时性更高的轻量化模型,为小样本学习在领域的创新发展和实战融合应用提供了参考。虽然目前小样本目标识别分类算法的发展还处于初步阶段,还未得到广泛应用,但随着目标识别分类的发展及小样本应用需求的日益增长,必然会广泛推动学术成果的产生。



参考文献

- [1] 韦世红,刘红梅,唐宏,等.多级度量网络的小样本学习[J].计算机工程与应用,2023,59(2):94-101.
- [2] 肖楚琬,刘嘉,唐小峰.面向智能决策的军事数据工程建设[J].指挥控制与仿真,2020,42(3):97-101.
- [3] MITCHELL T M. Machine Learning [M]. New York: McGraw-Hill,1997.
- [4] 王光博,陈亮.改进关系网络的小样本图像分类方法[J].沈阳理工大学学报,2023,42(1):28-34.
- [5] WANG Y Q, YAO Q M, KWOK J, et al. Generalizing from a Few Examples: A Survey on Few-shot Learning [EB/OL]. (2020-03-29) [2023-09-08]. <https://arxiv.org/abs/1904.05046>.
- [6] FREUND Y, SCHAPIRE R E. A Short Introduction to Boosting [J]. Journal of Japanese Society for Artificial Intelligence, 1999, 14(5): 771-780.
- [7] DALAL N, TRIGGS B. Histograms of Oriented Gradients for Human Detection [C] // 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. San Diego: IEEE, 2005: 886-893.
- [8] FELZENSZWALB P F, GIRSHICK R B, MCALLESTER D, et al. Object Detection with Discriminatively Trained Part-based Models [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2014, 32(9): 1627-1645.
- [9] HE K M, ZHANG X Y, REN S Q, et al. Deep Residual Learning for Image Recognition [C] // 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 770-778.
- [10] GOODFELLOW I J, POUGET-ABADIE J, MIRZA M, et al. Generative Adversarial Nets [EB/OL]. (2014-06-10) [2023-09-08]. <https://arxiv.org/abs/1406.2661>.
- [11] ANTONIOU A, STORKEY A, EDWARDS H. Data Augmentation Generative Adversarial Networks [EB/OL]. (2018-03-21) [2023-09-08]. <https://arxiv.org/abs/1711.04340>.
- [12] SCHWARTZ E, KARLINSKY L, SHTOK J, et al. Delta-encoder: An Effective Sample Synthesis Method for Few-shot Object Recognition [EB/OL]. (2018-11-29) [2023-09-08]. <https://arxiv.org/abs/1806.04734>.
- [13] YU Z J, CHEN L, CHENG Z W, et al. TransMatch: A Transfer-learning Scheme for Semi-supervised Few-shot Learning [C] // 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2020: 12853-12861.
- [14] LI Y T, ZHU H Y, CHENG Y, et al. Few-shot Object Detection via Classification Refinement and Distractor Retreatment [C] // 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville: IEEE, 2021: 15390-15398.
- [15] CHEN H, WANG Y L, WANG G Y, et al. LSTD: A Low-shot Transfer Detector for Object Detection [EB/OL]. (2018-03-05) [2023-09-08]. <https://arxiv.org/abs/1803.01529>.

- [16] WANG X, HUANG T E, DARRELL T, et al. Frustratingly Simple Few-shot Object Detection [EB/OL]. (2020-03-16) [2023-09-08]. <https://arxiv.org/abs/2003.06957>.
- [17] VINYALS O, BLUNDELL C, LILLICRAP T, et al. Matching Networks for One Shot Learning [EB/OL]. (2017-12-29) [2023-09-08]. <https://arxiv.org/abs/1606.04080>.
- [18] SUNG F, YANG Y, ZHANG L, et al. Learning to Compare: Relation Network for Few-shot Learning [EB/OL]. (2018-03-27) [2023-09-08]. <https://arxiv.org/abs/1711.06025>.
- [19] SIMON C, KONIUSZ P, NOCK R, et al. Adaptive Subspaces for Few-shot Learning [C]//2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2020: 4135-4144.
- [20] MEHROTA A, DUKKIPATI A. Generative Adversarial Residual Pairwise Networks for One Shot Learning [EB/OL]. (2017-03-23) [2023-09-08]. <https://arxiv.org/abs/1703.08033>.
- [21] 陈龙, 张峰, 蒋升. 小样本条件下基于深度森林学习模型的典型军事目标识别方法 [J]. 中国电子科学研究院学报, 2019, 14(3): 232-237.
- [22] ZHOU Z H, FENG J. Deep Forest: Towards an Alternative to Deep Neural Networks [EB/OL]. (2020-07-06) [2023-09-08]. <https://arxiv.org/abs/1702.08835v2>.
- [23] JIANG Y C, ZHU B, XIE B. Remote Sensing Images Data Augmentation Based on Style Transfer under the Condition of Few Samples [J]. Journal of Physics: Conference Series, 2020, 1653(1): 012039.
- [24] ZHU J Y, PARK T, ISOLA P, et al. Unpaired Image-to-Image Translation Using Cycle-consistent Adversarial Networks [C]//2017 IEEE International Conference on Computer Vision (ICCV). Venice: IEEE, 2017: 2242-2251.
- [25] 王亦倩. 基于小样本的雷达图像舰船目标检测识别 [D]. 西安: 西安电子科技大学, 2021.
- [26] 刘兴丽, 范俊杰, 马海群. 面向小样本命名实体识别的数据增强算法改进策略研究 [J]. 数据分析与知识发现, 2022, 6(10): 128-141.
- [27] WEI J, ZOU K. EDA: Easy Data Augmentation Techniques for Boosting Performance on Text Classification Tasks [EB/OL]. (2019-08-25) [2023-09-08]. <https://arxiv.org/abs/1901.11196>.
- [28] 胡安林. 基于生成对抗网络与迁移学习的小样本舰船目标检测 [D]. 重庆: 重庆大学, 2020.
- [29] SIMONYAN K, ZISSERMAN A. Very Deep Convolutional Networks for Large-scale Image Recognition [EB/OL]. (2015-04-10) [2023-09-08]. <https://arxiv.org/abs/1409.1556>.
- [30] SZEGEDY C, LIU W, JIA Y Q, et al. Going Deeper with Convolutions [C]//2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Boston: IEEE, 2015: 1-9.
- [31] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: Towards Real-time Object Detection with Region Proposal Networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(6): 1137-1149.
- [32] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-time Object Detection [C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR). Las Vegas: IEEE, 2016: 779-788.
- [33] 郭继光, 李奇峰. 基于迁移学习的小样本弹道导弹目标识别方法 [J]. 中国电子科学研究院学报, 2022, 17(7): 626-634.
- [34] 王美玉, 田乔. 迁移学习用于电磁目标识别 [J]. 太赫兹科学与电子信息学报, 2021, 19(4): 556-561.
- [35] 徐建, 阮国庆, 李晓冬, 等. 基于迁移学习的小样本军事文本命名实体识别 [C]//第九届中国指挥与控制学会. 北京: 兵器工业出版社, 2021: 292-295.
- [36] SNELL J, SWERSKY K, ZEMEL R S. Prototypical Networks for Few-shot Learning [EB/OL]. (2017-07-19) [2023-09-08]. <https://arxiv.org/abs/1703.05175>.
- [37] 刘旗, 张新禹, 刘永祥. 基于门控多尺度匹配网络的小样本 SAR 目标识别 [J]. 系统工程与电子技术, 2022, 44(11): 3346-3356.
- [38] 金璐, 刘士建, 王霄, 等. 基于改进关系网络的小样本红外空中目标识别分类方法 [J]. 光学学报, 2020, 40(8): 87-96.
- [39] 孟浩, 田洋, 孙宇婷, 等. 全局注意力关系网络的小样本船舶识别 [J]. 仪器仪表学报, 2021, 42(12): 220-227.
- [40] LIU Y C, SHAO Z R, HOFFMAN N. Global Attention Mechanism: Retain Information to Enhance Channel-Spatial Interactions [EB/OL]. (2021-12-10) [2023-09-08]. <https://arxiv.org/abs/2112.05561>.

作者简介

- 高 静 女, (1997—), 硕士, 助理工程师。
- 冯金顺 男, (1981—), 硕士, 高级工程师。
- 董少然 男, (1985—), 硕士, 高级工程师。
- 郭新苍 男, (1975—), 硕士, 高级工程师。
- 范烁晨 男, (1997—), 硕士, 助理工程师。
- 赵乾宏 男, (1976—), 硕士, 高级工程师。主要研究方向: 通信及信号处理。
- 朱光耀 男, (1997—), 硕士, 助理工程师。
- 陈家良 男, (1991—), 硕士, 助理工程师。
- 马胤焱 男, (1996—), 硕士, 助理工程师。